

Previsão de indicadores de uma rede UMTS utilizando análise de séries temporais

Carlos E. C. Costa¹

¹Centro de Ciências Exatas e Tecnologia
Programa de Pós-Graduação em Informática
Universidade Federal do Estado do Rio de Janeiro (UNIRIO)

Abstract. *Mobile networks such as UMTS and LTE have been experiencing a tremendous growth as we advance towards a connected world. Therefore, investments in network infrastructure is a constant demand which requires sophisticated methods capable of supporting network planning and resource optimization. In such context, this paper aims to explore and compare time series forecasting models using network KPIs collected from a real network. Three datasets were used containing number of HSDPA (High-Speed Downlink Packet Access) users, HSDPA data traffic and HSDPA Throughput which were trained and tested by a linear model ARIMA, a Neural Network Multilayer Perceptron and a Recurrent Neural Network Long Short Term Memory. The results were evaluated through the metrics MSE, MAE, MAPE presenting relatively good score and indicating the possibility to use such models to forecast KPIs and avoid network service quality degradation as well as plan network resource capacity it advance.*

1. Introdução

O crescente número de dispositivos conectados em rede em todo o mundo impacta no crescimento do tráfego em redes móveis de telecomunicações. Cada ano, vários novos dispositivos em diferentes formas e maior capacidade e inteligência são introduzidos no mercado. Segundo o portal online Statista, o número total de usuários de telefones celulares atingiu 4,43 bilhões em 2015. Esse número deve crescer para 4,61 bilhões em 2016 e 4,77 bilhões em 2017. O número de assinaturas de celular móvel é ainda maior atingindo 7 Bilhões.[1]

No Brasil, o tráfego de dados móveis crescerá 7 vezes entre 2015 e 2020, uma taxa composta de crescimento anual de 45%, de acordo a previsão feita pela Cisco[2].Consequentemente,as operadoras de redes móveis enfrentam atualmente desafios significativos. No plano econômico, suas receitas não estão crescendo ao mesmo ritmo da carga de tráfego, exigindo assim, dado o aumento da demanda de investimento em infraestrutura, análises técnicas eficientes e assertivas sobre as reais prioridades para o direcionamento dos recursos em infraestrutura nos locais onde se identifica maior necessidade.

Em redes móveis 3G e 4G (UMTS e LTE) é de suma importância evitar o congestionamento de recursos de rede, que como consequência, logo implicam em degradação da percepção do usuário sobre o serviço, estando este cada vez mais sensível às taxas de velocidade e atraso. Para isto é importante compreender o modelo de tráfego da operadora em diferentes regiões para que se possa efetuar um melhor planejamento e antecipar ações de investimento em capacidade ou otimização técnica dos recursos já existentes.

O monitoramento da performance de redes móveis é feito com base em indicadores chave de desempenho (KPIs), que são comumente usados para avaliar o desempenho de uma rede de telefonia celular, além de permitir o monitoramento do tráfego de rede, da distribuição de recursos e indicar gargalos de capacidade. Na grande maioria dos casos esses indicadores estão diretamente ligados à qualidade dos equipamentos de rede, no entanto alguns KPIs são criados com a finalidade de retratar a experiência do usuário ou qualidade do serviço. Tais indicadores são padronizados e definidos pela organização 3rd Generation Partnership Project (3GPP) através de especificações [3], cabendo a cada fabricante de equipamento definir a implementação dos contadores que suportam o cálculo numérico dos indicadores definidos. Alguns exemplos de KPIs de rede UMTS e LTE são: taxa de acessibilidade, queda de chamada, sucesso de mobilidade entre estações, velocidade, número de usuários por tecnologia, tráfego de rede, disponibilidade dos equipamentos, utilização de recursos.

Trabalhos relacionados

A aplicação de métodos de previsão de séries temporais baseadas em conceitos estatísticos lineares como métodos de exponential smoothing e autoregressive integrated moving average ou conexistas como redes neurais artificiais, principalmente com os avanços recentes como otimizações nas arquiteturas de redes neurais recorrentes, tem sido feita em diversas áreas como mercado financeiro, saúde, reconhecimento de padrões e engenharia. Alguns trabalhos desenvolvidos na intenção de utilizar tais métodos para fazer previsão de séries são descritos abaixo.

Um sistema de previsão inteligente para diagnóstico automotivo utilizando séries temporais foi proposto, como um método híbrido, em [4], com a utilização de ARIMA para modelar os aspectos lineares e uma rede neural MLP para modelar os aspectos não lineares através nos resíduos de ARIMA, considerando séries relacionadas as temperatura e a tensão da bateria do motor de um carro. Os resultados do modelo híbrido se apresentaram melhores em todas as métricas quando comparado ao melhor de ambos os modelos, quando considerados individualmente.

Em [5], diferentes arquiteturas de redes neurais artificiais são testadas na tentativa de obter a configuração que apresenta os melhores resultados na previsão de ocorrência de chuvas, considerando uma série temporal contendo 40 anos de dados de uma estação meteorológica localizada em Manaus, Amazonas.

A previsão do indicador Throughput (taxa de transferência) em uma rede LTE é abordada em [6], considerando dois cenários: a média de uma região inteira e o valor em apenas uma célula de rede. No trabalho dois modelos estatísticos são comparados, sendo eles ARIMA e Exponential Smoothing. O trabalho conclui que o modelo ARIMA é melhor para previsão de Throughput em dias de semana para uma região inteira, enquanto Exponential Smoothing apresentou melhores resultados quando no cenário considerado apenas uma célula.

Este trabalho estuda a utilização de modelos estatísticos lineares e não-lineares em dados reais coletados de uma operadora indicando número de usuários, tráfego de rede e Throughput (taxa de transferência) de usuário em determinadas regiões. Dessa forma, o modelo linear autoregressive integrated moving average (ARIMA) é comparado a modelos não lineares de redes neurais, multilayer Perceptron (MLP) e Long Short Term

Memory networks (LSTM).

O esboço do artigo é o seguinte. Na Seção 2, conceitos básicos sobre os modelos de previsão apresentados. Na Seção 3, será apresentada a descrição da base de dados e da metodologia utilizada. Na seção 4, serão apresentados os resultados numéricos detalhados obtidos a partir de uma configuração experimental. Finalmente, as conclusões e trabalhos futuros são indicados na Seção 5.

2. Previsão de séries temporais

Uma série temporal é um conjunto sequencial de dados, medidos normalmente em sucessivos intervalos de tempo e organizadas em uma ordem cronológica adequada. Sua análise é feita, normalmente, com o objetivo de detectar tendências de longo prazo ou prever valores futuros, entretanto também são utilizadas também para tarefas de clusterização e classificação. Uma série de temporal pode ser denominada univariada ou multivariada dependendo se contém de uma única variável de mais de uma variável, multivariada. Uma série temporal pode ser contínua ou discreta. Numa série de tempo contínua as observações são medidas em cada instância de tempo, enquanto que uma série temporal discreta contém observações medidas em pontos discretos de tempo. Séries deste tipo podem possuir quatro componentes principais, nas quais podem ser decompostas: tendência, ciclo, sazonalidade e componentes irregulares ou resíduo. Considerando estas componentes dois modelos são usados para descrever séries temporais: aditivo ou multiplicativo, podendo um modelo multiplicativo se tornar um aditivo através de uma transformação logaritmica [7]

Modelo Aditivo: $X(t) = T(t) + C(t) + S(t) + I(t)$

Modelo Multiplicativo: $X(t) = T(t) * C(t) * S(t) * I(t)$

O método estatístico ARIMA e as redes neurais Multilayer Perceptron (MLP) e Long Short Term Memory (LSTM) serão brevemente descritos abaixo.

2.1. Autoregressive Integrated Moving Average

O modelo ARIMA de Box & Jenkins é um dos métodos mais utilizados na análise de séries temporais. Este possui restrições para séries lineares e estacionárias e assume que a série siga uma distribuição estatística conhecida (e.g. distribuição normal). Ele possui, como casos particulares, os métodos Autoregressivo (AR) e Médias móveis (MA), sendo o valor futuro de uma série univariada uma função linear de observações passadas e erros aleatórios.

No processo estocástico $AR(p)$, o valor futuro de uma variável é assumido como sendo uma combinação linear de p observações passadas e um erro aleatório juntamente com um termo constante

$$x(t) = C + \sum_{i=1}^p \alpha_i * x_{t-i} + \epsilon_t$$

onde $\alpha_1 \dots \alpha_p$ são os parâmetros e p a ordem do modelo, C uma constante e o erro aleatório ϵ_t um ruído branco.

No processo $MA(q)$ os erros de previsões passados da equação de previsão são usados como a variável explicativa conforme fórmula abaixo:

$$x(t) = \mu + \epsilon_t + \sum_{i=1}^q \theta_i * \epsilon_{t-i}$$

onde $\theta_i \dots \theta_q$ são os parâmetros do modelo, q a ordem, μ a média da séries e $\epsilon_{t-1}, \epsilon_{t-2}, \dots, \epsilon_{t-q}$ os erros aleatórios.

Modelos ARIMA(p,i,q) são definidos para séries estacionárias, então o passo inicial na análise das séries é a verificação da estacionariedade da mesma. Isso pode ser feito através da visualização da séries e verificação se as propriedades estatísticas como média, variância e autocorrelação são constantes ao longo do tempo ou da aplicação de testes como Dickey-Fuller[9]. No caso de séries não-estacionárias, transformações como decomposição e diferenciação podem ser aplicadas para torná-las estacionárias. Nos modelos ARIMA, o parâmetro i representa a ordem da diferenciação utilizada para tornar a séries estacionária. A análise das funções de autocorrelação e de correlação parcial, ACF e PACF, respectivamente, são utilizadas tanto para determinar se o processo é AR(p) ou MA(q) como a ordem p e q do modelo ARIMA, pois estas medidas refletem como as observações estão correlacionadas entre si na série temporal.

2.2. Redes Neurais Artificiais

A forma linear das séries temporais pré-assumida pelo modelo ARIMA, tal como sua exigência de uma distribuição estatística particular são limitações que se tornam muitas vezes inadequado em situações práticas. As Redes Neurais Artificiais (RNAs) são modelos não-lineares que superam este inconveniente e que tem atraído grande atenção recentemente. Inspiradas biologicamente, estes modelos tem atingido resultados de sucesso em áreas como previsão e classificação e tentam reconhecer regularidades e padrões nos dados de entrada, aprender com a experiência e fornecer resultados generalizados com base em conhecimentos prévios.[7]. Abaixo dois tipos de Redes Neurais utilizados neste trabalho serão descritos.

2.2.1. Multilayer Perceptrons

As RNAs mais utilizadas em problemas de previsão são Multilayer Perceptrons(MLPs). O modelo é caracterizado por uma rede de três camadas, sendo uma de entrada (input layer), uma ou mais camadas escondidas (hidden layer)e uma saída (output layer), conectada por links. Os nós em várias camadas são também conhecidos como elementos de processamento[7]. Em previsão de séries, os dados de entrada consistem nos atrasos de tempo, ou os valores da séries nos instantes anteriores. Por exemplo, a utilização de quatros atrasos para previsão significaria os valores da séries x_{t-4}, \dots, x_t como entrada no input layer da rede neural, o que é conhecido como tamanho da janela (windows size). No output layer, se apenas 1 valor futuro é desejado então é necessário apenas um neurônio nesta camada, entretanto para o caso de previsão de múltiplos valores, como x_t, \dots, x_{t+l} , $l + 1$ neurônios deverão ser usados na camada de saída. A arquitetura de alimentação de três camadas de modelos RNA pode ser descrita como abaixo:




Figure 1. Arquitetura de uma RNA Multilayer Perceptron com 3 camadas feed forward

2.2.2. Long Short Term Memory

Redes Neurais Recorrentes (RNR) são modelos que capturam a dinâmica de seqüências através de ciclos na rede de nós e constituem, portanto, escolhas atrativas para problemas de modelagem de seqüências[10]. Estes modelos podem aprender o que armazenar e o que esquecer e conseguem reconhecerem padrões sequenciais na presença de distorções. Ao contrário das redes neurais feedforward padrão, as redes recorrentes retêm um estado que pode representar informações de uma janela de contexto arbitrariamente longa.

Long Short Term Memory (LSTM) networks são Redes Neurais Recorrentes capazes de aprender dependências de longo prazo. Elas foram introduzidas por Hochreiter & Schmidhuber (1997)[11], e foram refinadas obtendo muitas otimizações em sua arquitetura obtendo, atualmente, grande sucesso em aprendizagem em larga escala. Esta rede é treinada usando Backpropagation através do tempo e sua arquitetura tem como objetivo superar o problema conhecido como "Vanishing error problem"[12]. Em vez de neurônios, as redes LSTM possuem blocos de memória conectados por camadas. Um bloco tem componentes que o tornam mais esperto do que um neurônio clássico e uma memória para seqüências recentes. Um bloco contém portas que gerenciam o estado e a saída do bloco. Um bloco opera sobre uma seqüência de entrada e cada porta dentro de um bloco usa as unidades de ativação para controlar se elas são acionadas ou não, fazendo a mudança de estado e adição de informações fluindo através do bloco condicional.[13] Este modelo de rede funciona da seguinte forma: 1) forget layer decide que informações

devem ser esquecidas no estado da memória; 2) input layer decide que informações novas dos valores de entrada devem ser armazenadas no estado da memória; 3) o output layer decide a saída com base na entrada e na memória do bloco. As figuras abaixo representam a arquitetura de uma Rede Neural Recorrente LSTM.

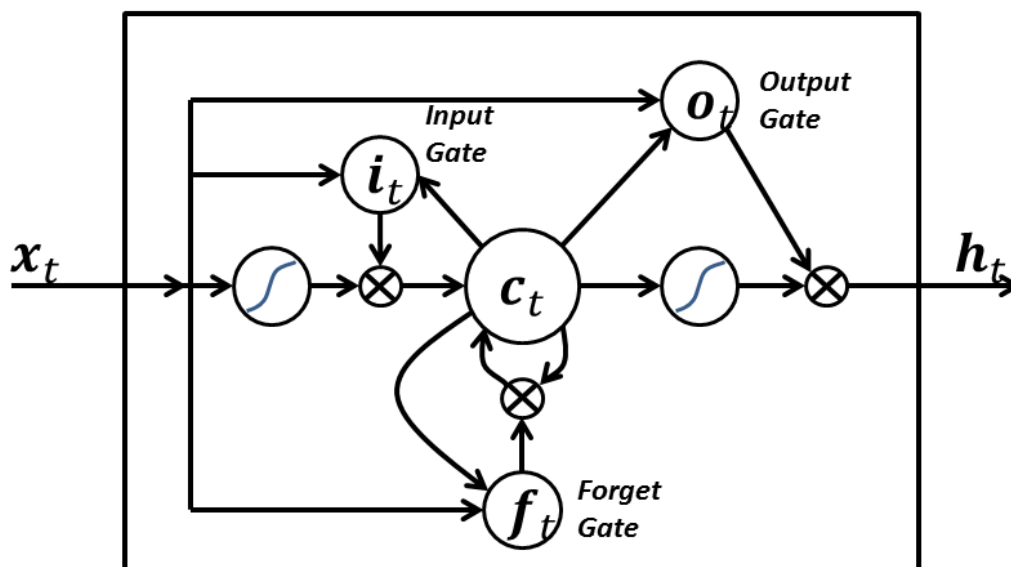


Figure 2. Arquitetura de uma Rede Neural Recorrente LSTM

3. Base de dados e Metodologia Utilizada

3.1. Descrição do dataset

A base de dados utilizada consiste em dados extraídos da rede 3G (UMTS) de uma operadora de telefonia celular no Brasil nos períodos 1 de janeiro de 2016 até 20 de abril de 2016 e 12 de setembro de 2016 até 30 de setembro de 2016. Os dados foram coletados por célula de rede para 244 células que cobrem a região do Lago Sul em Brasília(DF), em intervalos discretos de meia hora, sendo cada meia hora a agregação dos contadores armazenados no equipamento de rede Radio Network Controller (RNC) durante aquela meia hora. Além do id de rede da célula e do RNC, foram coletados contadores para cálculo de três indicadores (KPIs) de rede: Throughput (taxa de transferência), que consiste na média da taxa de velocidade de usuários HSDPA (High Speed Downlink Packet Access) na célula durante a meia hora em questão em kbps; Usuários HSDPA, que consiste na média do número de dispositivos conectados, ao mesmo tempo, em modo HSDPA, na meia hora em questão em uma célula; e Tráfego de dados(kB), que consiste na soma do volume de dados trafegado em uma célula na meia hora. A base foi dividida em 3 datasets, sendo um para cada indicador que serão descritos abaixo:

O dataset referente de número de usuários é composto por apenas uma célula de rede, escolhida por apresentar comportamento crescente durante os meses e refere-se ao período de 1 de janeiro de 2016 até 20 de abril de 2016. As meia horas foram agregadas em horas através da média. Apenas as 12 horas com maior tráfego de dados do dia foram selecionadas, o que consistiu no período de 11:00 até as 22:00, afim de reduzir a dimensão do dataset. Valores nulos foram eliminados do dataset, totalizando então 1290 linhas.

Os dados referentes aos KPIs volume de dados e ao Throughput foram tratados da mesma forma, mas separados em dois datasets diferentes. Ambos utilizam os dados de meia hora coletados entre os dias 12 de setembro 2016 e 30 de setembro de 2016 para as 244 células, entretanto o valor dos indicadores foi agregado para todas as células, formando-se então um cluster referente a cobertura da região do Lago Sul, DF. O volume de dados foi somado para todas as células e a média do Throughput foi feita. Devido ao comportamento de tráfego e, por conseguinte, da taxa de velocidade, serem bem diferentes em dias de semana e em fins de semana, ambos os períodos foram separados. No entanto, neste estudo, apenas os datasets referentes aos dias de semana foram utilizados. As linhas que apresentaram outliers ou dados serados por erro de coleta foram eliminadas dos datasets, totalizando então 707 linhas.

As figuras abaixo mostram a decomposição das séries temporais dos três datasets mencionados em suas componentes tendência, sazonalidade e resíduo. Pode-se verificar que a série referente ao número de usuário possui uma tendência de crescimento, enquanto




Figure 3. Decomposição da série temporal referente ao número de Usuários HSDPA




Figure 4. Decomposição da série temporal referente ao volume de dados HSDPA




Figure 5. Decomposição da série temporal referente ao Throughput HSDPA

3.2. Metodologia

Neste estudo será usada uma metodologia similar para modelar os três datasets e cada um será separado em treino e teste de forma sequencial, sendo 67% dos dados treino e 33% para teste.

O modelo ARIMA será parametrizado conforme os passos a seguir. 1) Visualização dos dados afim de verificar se a série é estacionária e se alguma transformação nos dados será necessária. 2) Normalização linear do indicador no intervalo $[0,1]$. 3) Separação do dataset em dois, sendo um para treino e o outro para testar o modelo. 4) Realização de teste Dickey Fuller. 5) Caso a série não apresente um comportamento estacionário, realizar diferenciação e, em seguida, os teste do item anterior novamente até que esta se torne estacionária. 6) Análise das funções ACF e PACF, para identificar se estas indicam um modelo $AR(p), MA(q)$ ou uma combinação de ambos. 7) Teste dos modelos de acordo com as funções mencionadas no item anterior e variação da configuração afim de encontrar o melhor modelo baseando-se no valor de akaike information criterion (AIC). 8) Avaliar as previsões do modelo encontrado utilizando as métricas MSE, MAE e MAPE que serão descritas na sessão seguinte.

Ambas as redes neurais serão treinadas, baseando-se no resultado da métrica Mean Square error (MSE) como loss function. O algoritmo Adam, um algoritmo para otimização baseada em gradiente de primeira ordem de funções objetivas estocásticas[14], será utilizado como método de otimização. O número de épocas (epochs), medida do número de vezes em que todos os vetores de treinamento são usados para atualizar os pesos, e o tamanho do lote (batch size), número de exemplos de treinamento que serão propagados pela rede de forma que o número de exemplos dividido pelo batch size remetem quantidade de iterações necessária para completar uma época, serão fixos em 200 e 2, respectivamente. Os dados de input serão transformados tanto para treino como para teste, de forma que o número de atrasos escolhido, que representará o tamanho da janela, seja o número de colunas de entrada. Sendo assim, se usarmos 4 atrasos, x_{t-3}, \dots, x_t , a série temporal, inicialmente com duas colunas (datetime e valor do KPI), passará a ter 4 colunas com o valor de cada um destes intervalos de tempo e uma quinta coluna, x_{t+1} , que será o valor a ser previsto.

A rede Multilayer Perceptron terá apenas uma camada oculta (hidden layer) e um neurônio na camada de saída, por se tratar de um problema de previsão da próxima amostra. O tamanho da janela (window size), relativa a quantidade de entradas na camada de entrada e, portanto, a quantidade de neurônios nesta camada, bem como a quantidade de neurônios na camada oculta serão parametrizados via teste e erro, de acordo com o resultado das métricas de avaliação MAPE, MAE e MSE que serão utilizadas. A função rectifier será usada na camada de entrada e na camada oculta, enquanto a função sigmoid será usada na camada de saída.

A rede LSTM tem uma camada visível com 1 entrada, uma camada escondida com 4 blocos LSTM, e uma camada de saída que faz uma previsão de valor único. A função de ativação sigmóide padrão é usada para os blocos LSTM. O tamanho da janela será parametrizado via teste e erro de acordo com o resultado das métricas mencionadas.




Figure 6. Função de Auto-correlação do dataset de usuários HSDPA




Figure 7. Função de Correlação Parcial do dataset de usuários HSDPA

4. Resultados numéricos

A tabela 1 mostra os resultados do modelo ARIMA, da Rede Neural Multilayer Perceptron e da Rede Neural Recorrente Long Short Term Memory para cada um dos datasets, considerando as 3 métricas mencionadas acima. Para o dataset de usuários HSDPA, o modelo ARIMA escolhido foi (1,0,1), considerando as funções ACF e PACF; a arquitetura da rede MLP consistiu em uma janela de 12 entradas, 16 neurônios na camada oculta e 1 neurônio na camada de saída; e a arquitetura na rede LSTM também utilizou 12 atrasos de entrada além dos 4 blocos na camada oculta. Para dataset de volume de dados, o modelo ARIMA escolhido foi (2,0,1) por apresentar o menor valor de AIC; Ambas as redes neurais MLP e LSTM utilizaram uma janela de 36 entradas, entretanto a MLP utilizou 15 neurônios na camada oculta, enquanto a LSTM utilizou os mesmos 4. Por fim,

Dataset	Modelo	MSE	MAE	MAPE	Tempo(s)
Usuários HSDPA	ARIMA(1,0,1)	0.01517	0.09857	16.68	
Usuários HSDPA	MLP(12,16,1)	0.01001	0.07696	12.97	30.37
Usuários HSDPA	LSTM(12,4,1)	0.01050	0.07911	13.23	201
Volume de dados	ARIMA(2,0,1)	0.00515	0.05652	41.01	
Volume de dados	MLP(36,15,1)	0.00308	0.04239	31.03	25.67
Volume de dados	LSTM(36,4,1)	0.00272	0.03810	22.14	128.37
Throughput	ARIMA(4,0,1)	0.01047	0.07931		
Throughput	MLP(36,15,1)	0.00822	0.07178		25.69
Throughput	LSTM(36,4,1)	0.00890	0.07379		126

Table 1. Resultados para todas os datasets e modelos

para o dataset de Throughput, foi escolhido o modelo ARIMA(4,0,1) por apresentar o menor valor de AIC enquanto as redes neurais utilizaram a mesma arquitetura do dataset de volume de dados. Os três datasets apresentaram resultado do teste estatístico Dickey-Fuller menor que o valor crítico de 1%, podendo assim ser consideradas estacionárias e não necessitaram um procedimento de diferenciação. Os três datasets foram avaliados de acordo com as métricas Mean Square Error(MSE), Mean Absolut Error(MAE) e Mean Absolut Percentage Error(MAPE) e, o tempo de execução para as redes neurais foi considerado. Todas as métricas quanto mais próximas de zero significam melhores resultados. As redes neurais apresentaram resultados melhores similares e melhores que o modelo ARIMA em todos os datasets. A rede MLP obteve resultados um pouco melhores nos datasets de usuários HSDPA e Throughput, enquanto a rede LSTM obteve vantagem no dataset de Volume de dados. O tempo de execução do treinamento para a rede LSTM é bem superior aos outros dois modelos.

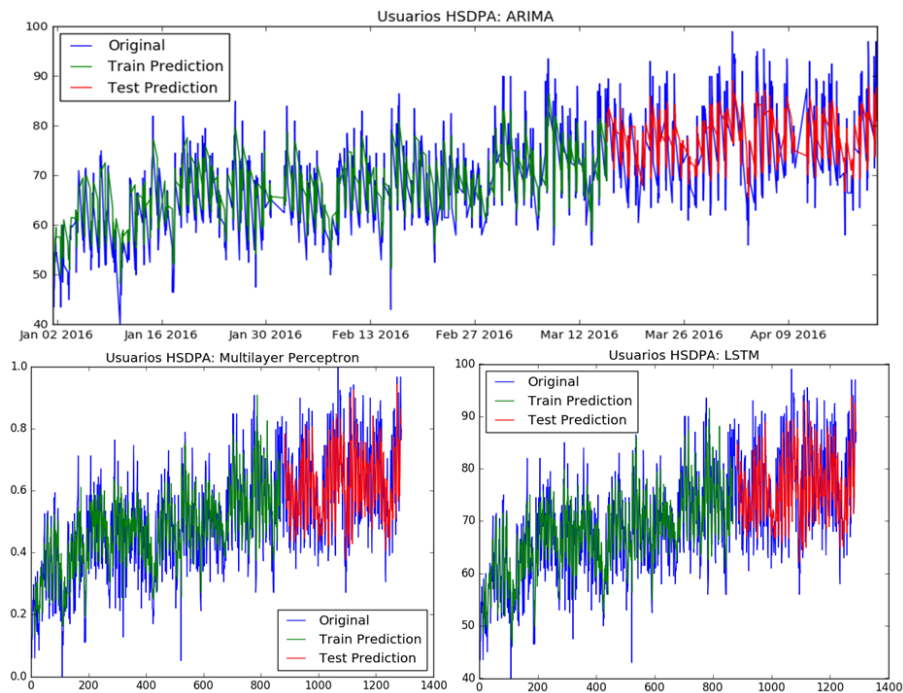


Figure 8. Usuários HSDPA




Figure 9. Throughput HSDPA: Modelo ARIMA




Figure 10. Throughput HSDPA: Modelo MLP




Figure 11. Throughput HSDPA: Modelo LSTM




Figure 12. Volume de dados HSDPA

5. Conclusões e trabalhos futuros

Este trabalho apresentou um estudo sobre previsão de séries temporais no contexto de monitoramento de indicadores (KPIs) de uma rede 3G UMTS de telefonia móvel. Três indicadores foram coletados de uma rede real de uma operadora e modelados, sendo eles: volume de dados (HSDPA), número de usuários HSDPA e Throughput (taxa de transferência) de usuários HSDPA. O dataset de usuário considerou dados de apenas uma célula e utilizou as 12 horas com maior número de usuários em um dia, enquanto os outros dois datasets utilizaram a agregação dos dados de todas as células coletadas formando um cluster referente a região do Lago Sul, DF e descartou os dados dos fins de semana. Três modelos diferentes foram testados, ARIMA, uma rede neural Multilayer Perceptron e uma rede neural recorrente Long Short Term Memory. As redes neurais apresentaram resultados similares e melhor que o modelo estatístico ARIMA, tendo a rede MLP apresentado resultado um pouco melhor em dois datasets e a rede LSTM em um.

É provável que tal performance superior da rede MLP tenha se dado pelo fato de a rede LSTM não ter tido seus parâmetros otimizados. Devido ao longo tempo de treinamento para as redes LSTM, propriedades importantes desta não foram utilizadas, como sua memória, não se considerando no estudo um de seus mais importantes benefícios na análise de séries e sequências. Acredita-se que com um melhor refinamento dos parâmetros da rede LSTM e a utilização dos principais benefícios de sua arquitetura lhe dariam maiores vantagens em comparação com os outros modelos. Os resultados obtidos na previsão foram bem próximos dos reais e a utilização destes métodos pode ajudar na previsão de quantidade de usuários, tráfego e taxa de transferência em redes UMTS. Dito isto, em trabalhos futuros deseja-se explorar melhor os parâmetros da rede neural recorrente LSTM e seus benefícios como a conservação de seu estado e memória, além de testar os modelos em datasets maiores, com mais de 1 ano de dados por exemplo. Deseja-se também explorar previsão de múltiplos instantes de tempo, utilizando mais neurônios na camada de saída, sendo assim, será possível prever em que momento um equipamento

alcançará limites de capacidade para que se possa, então, planejar e otimizar recursos de capacidade com antecedência afim de evitar degradações na rede e na percepção dos usuários.

6. References

- [1] STATISTA "Number of mobile phone users worldwide from 2013 to 2019 (in billions)". 2016. Disponível em: <https://www.statista.com/statistics/274774/forecast-of-mobile-phone-users-worldwide/>;
- [2] C.V.N. Index "Global Mobile Data Traffic Forecast Update". 2016. Disponível em: <http://www.cisco.com/c/en/us/solutions/collateral/service-provider/visual-networking-index-vni/mobile-white-paper-c11-520862.html>;
- [3] 3GPP "Specification". 2015. Disponível em: <https://portal.3gpp.org/desktopmodules/Specifications/SpecificationDetails.aspx?specificationId=2026>;
- [4] Almeida, D.M., Daniel C. Cunha, D.C., Neto, P. S. G. M., A Proposal of an Intelligent Forecasting System for Automotive Diagnostics using Time Series Analysis. UFPE.
- [5] Guedes, E. B., Lima, P. M., Oliveira, M. B. L.. Neural Networks for Time Series Rainfall Forecasting: A Case Study in Manaus, Amazonas. Universidade Estadual do Amazonas.
- [6] Dong, X., Fan, W., Gu, J. Predicting LTE Throughput Using Traffic Time Series. Beijing University of Posts and Telecommunications
- [7] Adhikari, R., Agrawal, R.K., An Introductory Study on Time Series Modeling and Forecasting.
- [8] ANALYTICSVIDHYA "A Complete Tutorial on Time Series Modeling in R". 2015. Disponível em: <https://www.analyticsvidhya.com/blog/2015/12/complete-tutorial-time-series-modeling/>;
- [9] Nau, R., Principles and risks of forecasting. Duke University. 2014. <https://people.duke.edu/~rnau/411diff.htm>;
- [10] Lipton, Z.C., Berkowitz, J., Elkan, C. A Critical Review of Recurrent Neural Networks for Sequence Learning. 2015. University of California San Diego.
- [11] COLAH "Understanding LSTM Networks". 2015. Disponível em: <http://colah.github.io/posts/2015-08-Understanding-LSTMs/>;
- [12] Gil, P.G. On the use of "Long-Short Term Memory" neural networks for time series prediction. Tijuana Institute of Technology. 2014
- [13] Brownlee, J., "Time Series Prediction with LSTM Recurrent Neural Networks in Python with Keras". 2016. Disponível em: <http://machinelearningmastery.com/time-series-prediction-lstm-recurrent-neural-networks-python-keras/>;
- [14] Kingma, D., Ba, J., Adam: A Method for Stochastic Optimization. 2015. Cornell University. Disponível em: <https://arxiv.org/abs/1412.6980v8>;
- [15] Jonge, E., Pelt, M., Roos, M. Time patterns, geospatial clustering and mobil-

ity statistics based on mobile phone network data. 2012. Statistics Netherlands

[16] Bergner, E., Unsupervised Learning of Traffic Patterns in Self-Optimizing 4th Generation Mobile Networks. 2012. Royal Institute of Technology.

[17] Joshi, M.R., Hadi, T.H., A Review of Network Traffic Analysis and Prediction Techniques. North Maharashtra University.